

# SME0123 – Estatística

---

**Cibele M. Russo**

com slides adaptados de Katiane Silva

Materiais da disciplina disponíveis em

<https://github.com/cibelerusso/EstatisticaI/>

**ICMC – USP**

Parte I - Probabilidade - Agosto de 2026

# Probabilidade

---

**Objetivo:**

Definir um modelo estatístico que seja adequado à descrição e interpretação de fenômenos aleatórios.

A princípio, vamos definir alguns conceitos básicos:

### Experimentos ou Fenômenos Aleatórios ( $E$ )

São situações ou acontecimentos cujos resultados não podem ser previstos com certeza, sob condições idênticas.

#### Exemplos:

$E_1$  : Lançamento de um dado (ou moeda).

$E_2$  : Tempo de vida útil de um componente eletrônico.

Na realização de um experimento aleatório **não podemos afirmar que um resultado particular ocorrerá**, porém podemos descrever o conjunto de **todos os resultados possíveis do experimento**, isto é, todas as possibilidades de resultado.

## Espaço Amostral ( $\Omega$ )

Refere-se ao conjunto de todos os resultados possíveis de um experimento ou fenômeno aleatório,

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_n, \dots\}.$$

**Exemplos:** Nos experimentos listados ( $E_1$  e  $E_2$ ), os espaços amostrais são:

$$\Omega_1 = \{1, 2, 3, 4, 5, 6\} \text{ (ou } \Omega_1 = \{\textit{cara}, \textit{coroa}\}).$$

$$\Omega_2 = [0, +\infty)$$

### Evento

Chamamos de **evento** qualquer subconjunto do espaço amostral  $\Omega$  de um experimento aleatório.

**Notação:**  $A, B, C, D, \dots$ , ou ainda,  $A_1, A_2, A_3, \dots$

Qualquer que seja o evento  $A$ , se  $A \subset \Omega$ , então  $A$  é um evento de  $\Omega$ . Assim, o evento aleatório pode ser um único ponto amostral ou uma reunião deles.

### Tipos de Eventos

- **Evento simples ou elementar:** É o evento formado por um único ponto amostral, isto é,  $A = \{\omega\}$  (conjunto unitário).
- **Evento composto:** É o evento formado por dois ou mais pontos do espaço amostral, isto é,  $A = \{\omega_1, \omega_2\}$ .
- **Evento certo:** É o evento formado por todos os pontos amostrais, isto é,  $A = \Omega$ .
- **Evento impossível:** É o evento que não possui elementos em  $\Omega$ , isto é,  $A = \emptyset$  ou  $A = \{ \}$ .

Um evento é sempre definido por uma sentença.

**Exemplo:** Um dado de seis faces ( $D_6$ ) é lançado e observa-se o número da face superior.

$A_1$  : “Obter um número maior que três e menor que cinco”;

$A_2$  : “Obter um número par”;

$A_3$  : “Obter um número menor ou igual a seis”;


$A_4$  : “Obter um número maior que seis”.




### Operações com Eventos

- Para ilustrar graficamente eventos, é costume utilizar-se os mesmos diagramas usados na teoria de conjuntos (diagrama de Venn).
- Para isso, considere eventos definidos em um espaço amostral  $\Omega$  de um experimento ou fenômeno aleatório.

1. **União de eventos ( $A \cup B$ ):** É o evento definido por todos os elementos que pertencem a  $A$ , ou a  $B$ , ou a ambos.




2. **Intersecção de eventos ( $A \cap B$ ):** É o evento definido por todos os elementos que pertencem a  $A$  e a  $B$ .




## Casos Particulares:


2.1 Se  $B \subset A$ , então  $A \cap B = B$ .




2.2 Se  $A$  e  $B$  são disjuntos ou eventos mutuamente exclusivos (não tem elementos comuns), então  $A \cap B = \emptyset$ .



3. **Diferença de eventos ( $A - B$ ):** É o evento definido pelos elementos de  $A$  que não pertencem a  $B$ .




4. **Evento Complementar ( $A^c$  ou  $\bar{A}$ ):** É o evento definido por todos elementos de  $\Omega$  que não estão em  $A$ .




## Alguns exemplos de eventos complementares:

4.1  $(A \cup B)^c = A^c \cap B^c$




$$4.2 \quad (A \cap B)^c = A^c \cup B^c$$




**Observação:** As igualdades (4.1) e (4.2) são conhecidas como **Leis de De Morgan**.

### 4.3 $A \cup B^c = (A \cap B) \cup B^c = A \cup (A \cup B)^c$




4.4  $A \cap B^c = (A \cup B) \cap B^c$



## Outras Operações:

1.  $A \cap \emptyset = \emptyset, \forall A;$
2.  $A \cup \emptyset = A;$
3.  $\emptyset^c$  ou  $\overline{\emptyset} = \Omega;$
4.  $\Omega^c$  ou  $\overline{\Omega} = \emptyset;$
5.  $(A^c)^c = A;$
6.  $B = (A \cap B) \cup (A^c \cap B);$
7.  $A = (A \cap B) \cup (A \cap B^c).$

**Exemplo 1.1:** Escrever  $A \cup B$  como a união de eventos disjuntos.



**Exercício Proposto 1.1:** Considere dois acontecimentos distintos  $A$  e  $B$ , possíveis e não certos, contidos no mesmo universo de resultados  $\Omega$ . Utilizando as Leis de De Morgan, qual outra representação teríamos para  $\overline{\overline{A \cup B} \cap A}$ .

**Dica:** Considere  $C = \overline{\overline{A \cup B}}$ .

**Resp.:**  $\overline{A} \cup B$ .

## Definições de Probabilidade

### Definição de probabilidade em espaços equiprováveis:

Se um experimento aleatório tiver  $n$  resultados possíveis,  $\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$ , mutuamente exclusivos e igualmente possíveis e se um evento  $A$  tiver  $n_A$  desses resultados, então a probabilidade do evento  $A$ , representada por  $P(A)$ , é dada por:

$$P(A) = \frac{n_A}{n}.$$

**Exemplo 1.2:** Lançamento de duas moedas honestas. Calcular a probabilidade de obter:

- a) Duas faces iguais.
- b) Pelo menos uma face diferente de cara.

### Definição de probabilidade frequentista:

Um experimento é realizado  $n$  vezes ( $n$  “grande”). O evento  $A$  ocorre exatamente  $n_A$  vezes ( $0 \leq n_A \leq n$ ). A frequência relativa de vezes que ocorreu o evento  $A$  é uma forma de aproximar a probabilidade do evento  $A$ , ou seja,

$$f_r(A) = \frac{n_A}{n}.$$

Quando  $n \rightarrow \infty$ ,  $f_r(A)$  se aproxima de  $P(A)$ .

**Exercício Proposto 1.2:** Considere o lançamento de uma moeda honesta  $n$  vezes e o evento de interesse é a face voltada para cima ser “cara”.

## Exemplo 1.2: Solução em Python.

```
import numpy as np

# Define o tamanho de lançamentos n
n = 100

# Gera n lançamentos de uma moeda:
# 0 representa coroa e 1 representa cara.
lancamentos = np.random.randint(0, 2, size=n)

num_caras = np.sum(lancamentos)
freq_relativa = num_caras / n

print("Número de caras:", num_caras)
print("Frequência relativa:", freq_relativa)
```

## Definição de probabilidade axiomática:

A probabilidade de um evento  $A$  é definida como sendo um número  $P(A)$  satisfazendo os seguintes axiomas:

- i  $P(A) \geq 0$ ;
- ii  $P(\Omega) = 1$ ;
- iii Se  $A_1, A_2, \dots$  são eventos mutuamente exclusivos, então

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

**Propriedades:**

- a)  $0 \leq P(A) \leq 1$ ;
- b)  $P(\emptyset) = 0$ ;
- c) Se  $A \subset \Omega$ , então  $P(A) = 1 - P(A^c)$ ;
- d) Se  $A \subset B \subset \Omega$ , então  $P(A) \leq P(B)$ ;
- e) Se  $A, B \subset \Omega$ , então vale  $P(B) = P(B \cap A) + P(B \cap A^c)$ ;
- f) Se  $A, B \subset \Omega$ , então vale  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ ;
- g) Se  $A, B, C \subset \Omega$ , então vale

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C).$$

**Exemplo 1.3:** Mostre a propriedade (g). Use o fato:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

**Exercício Proposto 1.3:** Considere um experimento aleatório e os eventos  $A$  e  $B$  associados, tais que:  $P(A) = \frac{1}{2}$ ;  $P(B) = \frac{1}{3}$  e  $P(A \cap B) = \frac{1}{4}$ . Calcule as probabilidades:

a)  $P(A^c \cap B^c)$ .

b)  $P(A^c \cup B^c)$ .

**Resp.:** a)  $\frac{5}{12}$ ; b)  $\frac{3}{4}$ .

## Probabilidade Condicional e Independência

### Definição (Probabilidade Condicional):

Sejam  $A$  e  $B$  dois eventos definidos em um mesmo espaço amostral  $\Omega$ . A probabilidade condicional de  $A$  dado que ocorreu o evento  $B$ , denotada por  $P(A|B)$ , é definida como

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \text{ se } P(B) > 0.$$

Consequentemente, podemos escrever:

$$P(A \cap B) = P(A|B)P(B),$$

conhecida como a **regra do produto de probabilidades**.


**Exemplo 1.4:** Suponha que um escritório possua 100 computadores dos tipos desktop ( $D$ ) e laptop ( $L$ ) sendo alguns novos ( $N$ ) e outros com um certo tempo de uso ( $U$ ), distribuídos da seguinte forma:

|       | $D$ | $L$ | Total |
|-------|-----|-----|-------|
| $N$   | 40  | 30  | 70    |
| $U$   | 20  | 10  | 30    |
| Total | 60  | 40  | 100   |

Um funcionário escolhe um laptop ao acaso. Qual a probabilidade de que seja novo?

## Árvore de Probabilidades:

Sejam  $A, B \subset \Omega$ . Uma representação bastante útil é a árvore de probabilidades.



**Exemplo 1.5:** Considerando as informações do **Exemplo 1.4**, qual a probabilidade de um funcionário selecionar um desktop usado? Utilize a árvore de probabilidades.

**Algumas Propriedades:**

- a)  $P(\emptyset|B) = 0$ ;
- b) Se  $A \subset \Omega$ , então  $P(A|B) = 1 - P(A^c|B)$ ;
- c) Se  $A, C \subset \Omega$ , então vale

$$P(A \cup C|B) = P(A|B) + P(C|B) - P(A \cap C|B).$$

### Definição (Independência de Eventos):

Dois eventos  $A$  e  $B$  definidos em um mesmo espaço amostral  $\Omega$  são independentes se a informação da ocorrência ou não de  $B$  não altera a probabilidade de ocorrência de  $A$ . Isto é,

$$P(A|B) = P(A), \text{ se } P(B) > 0.$$

Logo, dois eventos  $A$  e  $B$  são independentes se, e somente se,

$$P(A \cap B) = P(A)P(B).$$

### Exemplo 1.6: recuperação de dados

Após a corrupção de um arquivo, dois algoritmos de recuperação são executados:

- o algoritmo *A* recupera o arquivo com probabilidade de 30%;
- o algoritmo *B* recupera o arquivo com probabilidade de 50%.

Supondo que os resultados dos algoritmos sejam independentes, qual é a probabilidade de que **pelo menos um deles consiga recuperar o arquivo?**

### Independência de 3 Eventos:

Os eventos  $A$ ,  $B$  e  $C$  em  $\Omega$  são independentes se, e somente se:


- a)  $P(A \cap B) = P(A)P(B)$ ;
- b)  $P(A \cap C) = P(A)P(C)$ ;
- c)  $P(B \cap C) = P(B)P(C)$ ;
- d)  $P(A \cap B \cap C) = P(A)P(B)P(C)$ .

**Resultado:** Se  $A$  e  $B$  são eventos independentes em  $\Omega$ , então:

- (i)  $A$  e  $B^c$  são independentes;
- (ii)  $A^c$  e  $B$  são independentes;
- (iii)  $A^c$  e  $B^c$  são independentes.

**Observação:** Não confundir eventos mutuamente exclusivos ( $P(A \cap B) = 0$ ) com eventos independentes ( $P(A \cap B) = P(A)P(B)$ ).

**Dem. (i)]:**  $P(A \cap B^c) = ?$



Uma vez que  $A = (A \cap B^c) \cup (A \cap B)$ , união de eventos disjuntos, temos:

$$\begin{aligned}P(A \cap B^c) &= P(A) - P(A \cap B) \\&= P(A) - P(A)P(B) \\&= P(A)(1 - P(B)) \\&= P(A)P(B^c).\end{aligned}$$

### Exemplo 1.7: detecção de ataques

Dois sistemas de segurança monitoram, de forma independente, as requisições recebidas por um servidor.

- O sistema  $A$  detecta 80% dos ataques;
- o sistema  $B$  detecta 70% dos ataques.

Se uma requisição maliciosa for recebida, qual é a probabilidade de que **pelo menos um dos sistemas detecte o ataque?**


## O Teorema de Bayes

### Partição do Espaço Amostral: definição.

Uma coleção de eventos  $A_1, A_2, \dots, A_k$  forma uma partição do espaço amostral  $\Omega$  se:

(i)  $A_i \cap A_j = \emptyset, \forall i \neq j, i, j = 1, 2, \dots, k;$


(ii)  $\bigcup_{i=1}^k A_i = \Omega.$



## Lema da Probabilidade Total.

Se  $A_1, A_2, \dots, A_k$  é uma partição do espaço amostral  $\Omega$ , então para qualquer evento  $B$  de  $\Omega$  vale:

$$\begin{aligned} P(B) &= \sum_{i=1}^k P(B \cap A_i) \\ &= \sum_{i=1}^k P(B|A_i)P(A_i). \end{aligned}$$



## Fórmula de Bayes.

Se  $A_1, A_2, \dots, A_k$  formam uma partição do espaço amostral  $\Omega$  e  $B \subset \Omega$  com  $P(B) > 0$ , então:

$$\begin{aligned} P(A_i|B) &= \frac{P(A_i \cap B)}{P(B)} \\ &= \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^k P(B|A_j)P(A_j)}. \end{aligned}$$

**Exemplo 1.8: diagnóstico de falhas**

Um balanceador de carga distribui as requisições de uma aplicação entre dois servidores,  $A$  e  $B$ .

- O servidor  $A$  recebe 30% das requisições e apresenta falha em 10% delas;
- o servidor  $B$  recebe 70% das requisições e apresenta falha em 5% delas.

Uma requisição é selecionada aleatoriamente. Calcule:

1. a probabilidade de a requisição apresentar falha;
2. sabendo que a requisição apresentou falha, a probabilidade de ela ter sido processada pelo servidor  $A$ .

### Exercício proposto 1.4: filtro de spam

Em um servidor de e-mail, 40% das mensagens recebidas são classificadas, após verificação, como spam.

Um novo filtro automático apresenta o seguinte desempenho:

- identifica corretamente todas as mensagens que são spam;
- classifica incorretamente como spam 5% das mensagens legítimas.

Uma mensagem é selecionada aleatoriamente e o filtro a classifica como spam.

Qual é a probabilidade de que essa mensagem seja realmente spam?

**Resp.:** 0,9302, ou aproximadamente 93,02%.

**Exercício Proposto 1.5:** Após uma revisão completa, módulos de software são classificados quanto à qualidade do código:

- 25% são classificados como bons ( $B$ );
- 50% são classificados como médios ( $M$ );
- 25% são classificados como fracos ( $F$ ).

Uma ferramenta automática realiza uma análise preliminar e fornece os resultados aprovado ( $A$ ) ou reprovado ( $R$ ). Sabe-se que:

$$P(A | B) = 0,8, \quad P(A | M) = 0,5, \quad P(A | F) = 0,2.$$

Se um módulo foi aprovado pela ferramenta automática, qual é a probabilidade de que ele seja classificado como fraco em uma revisão completa?

**Resp.:** 0,1, ou 10%.