

SME0123 – Estatística

Cibele M. Russo

com slides adaptados de Katiane Silva

Materiais da disciplina disponíveis em

<https://github.com/cibelerusso/EstatisticaI/>

ICMC – USP

Parte I - Probabilidade - Agosto de 2026

Probabilidade

Objetivo:

Definir um modelo estatístico que seja adequado à descrição e interpretação de fenômenos aleatórios.

A princípio, vamos definir alguns conceitos básicos:

Experimentos ou Fenômenos Aleatórios (E)

São situações ou acontecimentos cujos resultados não podem ser previstos com certeza, sob condições idênticas.

Exemplos:

E_1 : Lançamento de um dado (ou moeda).

E_2 : Tempo de vida útil de um componente eletrônico.

Na realização de um experimento aleatório **não podemos afirmar que um resultado particular ocorrerá**, porém podemos descrever o conjunto de **todos os resultados possíveis do experimento**, isto é, todas as possibilidades de resultado.

Espaço Amostral (Ω)

Refere-se ao conjunto de todos os resultados possíveis de um experimento ou fenômeno aleatório,

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_n, \dots\}.$$

Exemplos: Nos experimentos listados (E_1 e E_2), os espaços amostrais são:

$$\Omega_1 = \{1, 2, 3, 4, 5, 6\} \text{ (ou } \Omega_1 = \{\textit{cara, coroa}\}).$$

$$\Omega_2 = [0, +\infty)$$

Evento

Chamamos de **evento** qualquer subconjunto do espaço amostral Ω de um experimento aleatório.

Notação: $A, B, C, D, \dots$, ou ainda, $A_1, A_2, A_3, \dots$

Qualquer que seja o evento A , se $A \subset \Omega$, então A é um evento de Ω . Assim, o evento aleatório pode ser um único ponto amostral ou uma reunião deles.

Tipos de Eventos

- **Evento simples ou elementar:** É o evento formado por um único ponto amostral, isto é, $A = \{\omega\}$ (conjunto unitário).
- **Evento composto:** É o evento formado por dois ou mais pontos do espaço amostral, isto é, $A = \{\omega_1, \omega_2\}$.
- **Evento certo:** É o evento formado por todos os pontos amostrais, isto é, $A = \Omega$.
- **Evento impossível:** É o evento que não possui elementos em Ω , isto é, $A = \emptyset$ ou $A = \{ \}$.

Um evento é sempre definido por uma sentença.

Exemplo: Um dado de seis faces (D_6) é lançado e observa-se o número da face superior.

A_1 : “Obter um número maior que três e menor que cinco”;

A_2 : “Obter um número par”;

A_3 : “Obter um número menor ou igual a seis”;


A_4 : “Obter um número maior que seis”.




Operações com Eventos

- Para ilustrar graficamente eventos, é costume utilizar-se os mesmos diagramas usados na teoria de conjuntos (diagrama de Venn).
- Para isso, considere eventos definidos em um espaço amostral Ω de um experimento ou fenômeno aleatório.

1. **União de eventos ($A \cup B$):** É o evento definido por todos os elementos que pertencem a A , ou a B , ou a ambos.




2. **Intersecção de eventos ($A \cap B$):** É o evento definido por todos os elementos que pertencem a A e a B .




Casos Particulares:


2.1 Se $B \subset A$, então $A \cap B = B$.




2.2 Se A e B são disjuntos ou eventos mutuamente exclusivos (não tem elementos comuns), então $A \cap B = \emptyset$.



3. **Diferença de eventos ($A - B$):** É o evento definido pelos elementos de A que não pertencem a B .




4. **Evento Complementar (A^c ou $\bar{A}$):** É o evento definido por todos elementos de Ω que não estão em A .




Alguns exemplos de eventos complementares:

4.1 $(A \cup B)^c = A^c \cap B^c$




$$4.2 \quad (A \cap B)^c = A^c \cup B^c$$




Observação: As igualdades (4.1) e (4.2) são conhecidas como **Leis de DeMorgan**.

4.3 $A \cup B^c = (A \cap B) \cup B^c = A \cup (A \cup B)^c$




4.4 $A \cap B^c = (A \cup B) \cap B^c$



Outras Operações:

1. $A \cap \emptyset = \emptyset, \forall A;$
2. $A \cup \emptyset = A;$
3. $\emptyset^c$ ou $\overline{\emptyset} = \Omega;$
4. Ω^c ou $\overline{\Omega} = \emptyset;$
5. $(A^c)^c = A;$
6. $B = (A \cap B) \cup (A^c \cap B);$
7. $A = (A \cap B) \cup (A \cap B^c).$

Exemplo 1.1: Escrever $A \cup B$ como a união de eventos disjuntos.



Exercício Proposto 1.1: Considere dois acontecimentos distintos A e B , possíveis e não certos, contidos no mesmo universo de resultados Ω . Utilizando as Leis de DeMorgan, qual outra representação teríamos para $\overline{\overline{A \cup B} \cap A}$.

Dica: Considere $C = \overline{\overline{A \cup B}}$.

Resp.: $\overline{A} \cup B$.

Definições de Probabilidade

Definição de probabilidade em espaços equiprováveis:

Se um experimento aleatório tiver n resultados possíveis, $\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$, mutuamente exclusivos e igualmente possíveis e se um evento A tiver n_A desses resultados, então a probabilidade do evento A , representada por $P(A)$, é dada por:

$$P(A) = \frac{n_A}{n}.$$

Exemplo 1.2: Lançamento de duas moedas honestas. Calcular a probabilidade de obter:

- a) Duas faces iguais.
- b) Pelo menos uma face diferente de cara.

Definição de probabilidade frequentista:

Um experimento é realizado n vezes (n “grande”). O evento A ocorre exatamente n_A vezes ($0 \leq n_A \leq n$). A frequência relativa de vezes que ocorreu o evento A é uma forma de aproximar a probabilidade do evento A , ou seja,

$$f_r(A) = \frac{n_A}{n}.$$

Quando $n \rightarrow \infty$, $f_r(A)$ se aproxima de $P(A)$.

Exercício Proposto 1.2: Considere o lançamento de uma moeda honesta n vezes e o evento de interesse é a face voltada para cima ser “cara”.

Exemplo 1.2: Solução em Python.

```
import numpy as np

# Define o tamanho de lançamentos n
n = 100

# Gera n lançamentos de uma moeda:
# 0 representa coroa e 1 representa cara.
lancamentos = np.random.randint(0, 2, size=n)

num_caras = np.sum(lancamentos)
freq_relativa = num_caras / n

print("Número de caras:", num_caras)
print("Frequência relativa:", freq_relativa)
```

Definição de probabilidade axiomática:

A probabilidade de um evento A é definida como sendo um número $P(A)$ satisfazendo os seguintes axiomas:

- i $P(A) \geq 0$;
- ii $P(\Omega) = 1$;
- iii Se $A_1, A_2, \dots$ são eventos mutuamente exclusivos, então

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Propriedades:

- a) $0 \leq P(A) \leq 1$;
- b) $P(\emptyset) = 0$;
- c) Se $A \subset \Omega$, então $P(A) = 1 - P(A^c)$;
- d) Se $A \subset B \subset \Omega$, então $P(A) \leq P(B)$;
- e) Se $A, B \subset \Omega$, então vale $P(B) = P(B \cap A) + P(B \cap A^c)$;
- f) Se $A, B \subset \Omega$, então vale $P(A \cup B) = P(A) + P(B) - P(A \cap B)$;
- g) Se $A, B, C \subset \Omega$, então vale

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C).$$

Exemplo 1.3: Mostre a propriedade (g). Use o fato:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

Exercício Proposto 1.3: Considere um experimento aleatório e os eventos A e B associados, tais que: $P(A) = \frac{1}{2}$; $P(B) = \frac{1}{3}$ e $P(A \cap B) = \frac{1}{4}$. Calcule as probabilidades:

a) $P(A^c \cap B^c)$.

b) $P(A^c \cup B^c)$.

Resp.: a) $\frac{5}{12}$; b) $\frac{3}{4}$.

Probabilidade Condicional e Independência

Definição (Probabilidade Condicional):

Sejam A e B dois eventos definidos em um mesmo espaço amostral Ω . A probabilidade condicional de A dado que ocorreu o evento B , denotada por $P(A|B)$, é definida como

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \text{ se } P(B) > 0.$$

Consequentemente, podemos escrever:

$$P(A \cap B) = P(A|B)P(B),$$

conhecida como a **regra do produto de probabilidades**.


Exemplo 1.4: Suponha que um escritório possua 100 computadores dos tipos desktop (D) e laptop (L) sendo alguns novos (N) e outros com um certo tempo de uso (U), distribuídos da seguinte forma:

	D	L	Total
N	40	30	70
U	20	10	30
Total	60	40	100

Um funcionário escolhe um laptop ao acaso. Qual a probabilidade de que seja novo?

Árvore de Probabilidades:

Sejam $A, B \subset \Omega$. Uma representação bastante útil é a árvore de probabilidades.



Exemplo 1.5: Considerando as informações do **Exemplo 1.4**, qual a probabilidade de um funcionário selecionar um desktop usado? Utilize a árvore de probabilidades.

Algumas Propriedades:

- a) $P(\emptyset|B) = 0$;
- b) Se $A \subset \Omega$, então $P(A|B) = 1 - P(A^c|B)$;
- c) Se $A, C \subset \Omega$, então vale

$$P(A \cup C|B) = P(A|B) + P(C|B) - P(A \cap C|B).$$

Definição (Independência de Eventos):

Dois eventos A e B definidos em um mesmo espaço amostral Ω são independentes se a informação da ocorrência ou não de B não altera a probabilidade de ocorrência de A . Isto é,

$$P(A|B) = P(A), \text{ se } P(B) > 0.$$

Logo, dois eventos A e B são independentes se, e somente se,

$$P(A \cap B) = P(A)P(B).$$

Exemplo 1.6: recuperação de dados

Após a corrupção de um arquivo, dois algoritmos de recuperação são executados:

- o algoritmo *A* recupera o arquivo com probabilidade de 30%;
- o algoritmo *B* recupera o arquivo com probabilidade de 50%.

Supondo que os resultados dos algoritmos sejam independentes, qual é a probabilidade de que **pelo menos um deles consiga recuperar o arquivo?**

Independência de 3 Eventos:

Os eventos A , B e C em Ω são independentes se, e somente se:


- a) $P(A \cap B) = P(A)P(B)$;
- b) $P(A \cap C) = P(A)P(C)$;
- c) $P(B \cap C) = P(B)P(C)$;
- d) $P(A \cap B \cap C) = P(A)P(B)P(C)$.

Resultado: Se A e B são eventos independentes em Ω , então:

- (i) A e B^c são independentes;
- (ii) A^c e B são independentes;
- (iii) A^c e B^c são independentes.

Observação: Não confundir eventos mutuamente exclusivos ($P(A \cap B) = 0$) com eventos independentes ($P(A \cap B) = P(A)P(B)$).

Dem. (i)]: $P(A \cap B^c) = ?$



Uma vez que $A = (A \cap B^c) \cup (A \cap B)$, união de eventos disjuntos, temos:

$$\begin{aligned}P(A \cap B^c) &= P(A) - P(A \cap B) \\&= P(A) - P(A)P(B) \\&= P(A)(1 - P(B)) \\&= P(A)P(B^c).\end{aligned}$$

Exemplo 1.7: detecção de ataques

Dois sistemas de segurança monitoram, de forma independente, as requisições recebidas por um servidor.

- O sistema A detecta 80% dos ataques;
- o sistema B detecta 70% dos ataques.

Se uma requisição maliciosa for recebida, qual é a probabilidade de que **pelo menos um dos sistemas detecte o ataque?**


O Teorema de Bayes

Partição do Espaço Amostral: definição.

Uma coleção de eventos $A_1, A_2, \dots, A_k$ forma uma partição do espaço amostral Ω se:

(i) $A_i \cap A_j = \emptyset, \forall i \neq j, i, j = 1, 2, \dots, k;$


(ii) $\bigcup_{i=1}^k A_i = \Omega.$



Lema da Probabilidade Total.

Se $A_1, A_2, \dots, A_k$ é uma partição do espaço amostral Ω , então para qualquer evento B de Ω vale:

$$\begin{aligned} P(B) &= \sum_{i=1}^k P(B \cap A_i) \\ &= \sum_{i=1}^k P(B|A_i)P(A_i). \end{aligned}$$



Fórmula de Bayes.

Se $A_1, A_2, \dots, A_k$ formam uma partição do espaço amostral Ω e $B \subset \Omega$ com $P(B) > 0$, então:

$$\begin{aligned} P(A_i|B) &= \frac{P(A_i \cap B)}{P(B)} \\ &= \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^k P(B|A_j)P(A_j)}. \end{aligned}$$

Exemplo 1.8: diagnóstico de falhas

Um balanceador de carga distribui as requisições de uma aplicação entre dois servidores, A e B .

- O servidor A recebe 30% das requisições e apresenta falha em 10% delas;
- o servidor B recebe 70% das requisições e apresenta falha em 5% delas.

Uma requisição é selecionada aleatoriamente. Calcule:

1. a probabilidade de a requisição apresentar falha;
2. sabendo que a requisição apresentou falha, a probabilidade de ela ter sido processada pelo servidor A .

Exercício proposto 1.4: filtro de spam

Em um servidor de e-mail, 40% das mensagens recebidas são classificadas, após verificação, como spam.

Um novo filtro automático apresenta o seguinte desempenho:

- identifica corretamente todas as mensagens que são spam;
- classifica incorretamente como spam 5% das mensagens legítimas.

Uma mensagem é selecionada aleatoriamente e o filtro a classifica como spam.

Qual é a probabilidade de que essa mensagem seja realmente spam?

Resp.: 0,9302, ou aproximadamente 93,02%.

Exercício Proposto 1.5: Após uma revisão completa, módulos de software são classificados quanto à qualidade do código:

- 25% são classificados como bons (B);
- 50% são classificados como médios (M);
- 25% são classificados como fracos (F).

Uma ferramenta automática realiza uma análise preliminar e fornece os resultados aprovado (A) ou reprovado (R). Sabe-se que:

$$P(A | B) = 0,8, \quad P(A | M) = 0,5, \quad P(A | F) = 0,2.$$

Se um módulo foi aprovado pela ferramenta automática, qual é a probabilidade de que ele seja classificado como fraco em uma revisão completa?

Resp.: 0,1, ou 10%.