SME0123 – Estatística

Cibele M. Russo
com slides adaptados de Katiane Silva

Materiais da disciplina disponíveis em
`https://github.com/cibelerusso/EstatisticaI/`

ICMC – USP

Parte V - Inferência Estatística - Outubro de 2026

Introdução à Inferência Estatística

Objetivo:

Extrair conhecimento e tomar decisões sobre dada característica da população na qual estamos interessados, a partir de informações colhidas de uma parte dessa população (amostra).

Característica: Variável Aleatória

- $X : \Omega \to \mathbb{R}$
- $X : p_X(x;\theta)$ ou $f_X(x;\theta) \to$ Modelo estatístico.

- Se tivéssemos a informação completa sobre a f.m.p. ou f.d.p. da variável de interesse, não teríamos necessidade de coletar uma amostra, uma vez que toda informação desejada seria obtida por meio da distribuição da variável.
  - **Situação Prática:** θ (parâmetro) desconhecido.
  - **Interesse:** Estimar θ (Métodos de Estimação Pontual).

- Para isso, considere uma amostra aleatória de X:

$$\boldsymbol{X} = (X_1, X_2, \ldots, X_n).$$

- Cada X_i, $i = 1, 2, \ldots, n$, é independente e tem a mesma distribuição de X.
- Associada a uma amostra aleatória $\boldsymbol{X}$, temos o vetor de observações:

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_n).$$

- Com base na amostra aleatória podemos obter uma estatística ou estimador, que é função da amostra aleatória:

$$T = T(\boldsymbol{X}) = T(X_1, X_2, \ldots, X_n).$$

- As estatísticas mais comuns são:

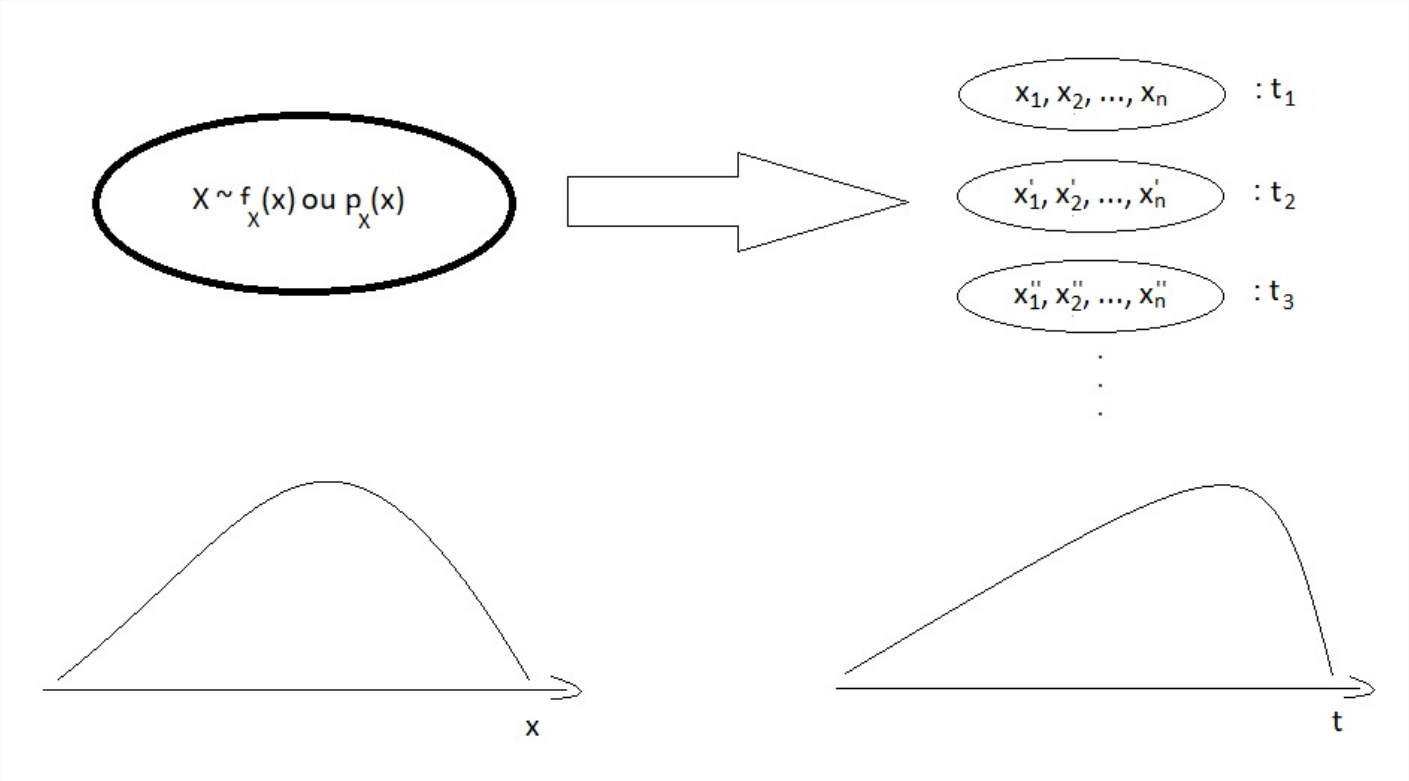
1. Média amostral: $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$
2. Variância amostral: $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$
3. Menor valor da amostra: $X_{(1)} = \min(X_1, X_2, \ldots, X_n)$
4. Maior valor da amostra: $X_{(n)} = \max(X_1, X_2, \ldots, X_n)$

O Problema da Inferência Estatística: é fazer uma afirmação sobre os parâmetros da população através da amostra.

Exemplos: afirmações sobre a média, variância ou qualquer outra medida.

- Nossa decisão será baseada na estatística T.
- Colhida uma amostra observada, $\boldsymbol{x} = (x_1, x_2, \ldots, x_n)$, teremos observado um particular valor de T, dito t.
- Baseado nesse valor t é que faremos afirmação sobre θ, o parâmetro populacional.

- A validade da nossa resposta seria melhor compreendida se soubéssemos o que acontece com a estatística *T* quando retiramos todas as amostras de uma população conhecida.



- Ou seja: qual a distribuição de T quando $X_1, X_2, \ldots, X_n$ assume todos os possíveis valores?
- Essa distribuição é chamada de distribuição amostral da estatística T.
- Vale ressaltar que a distribuição de T irá depender da distribuição de X.

Exercício Proposto 6.1: Considere a população $\{1, 3, 5, 5, 7\}$. Defina a variável X o valor assumido pelo elemento na população e desejamos coletar amostra de tamanho 2 ($n = 2$), com reposição.

a) Encontre a distribuição de X, $E(X)$ e $Var(X)$.

b) Encontre a distribuição conjunta da variável bidimensional (X_1, X_2).

c) Considere a estatística $T = T(X_1, X_2) = \overline{X} = \dfrac{X_1 + X_2}{2}$, a média amostral. Qual a distribuição da estatística?

d) Calcule $E(\overline{X})$ e $Var(\overline{X})$.

- Com um procedimento análogo ao **Exercício Proposto 6.1**, podemos obter as distribuições amostrais de outras estatísticas de interesse.

- Seguindo essa ideia, iremos estudar distribuições amostrais de algumas estatísticas importantes.

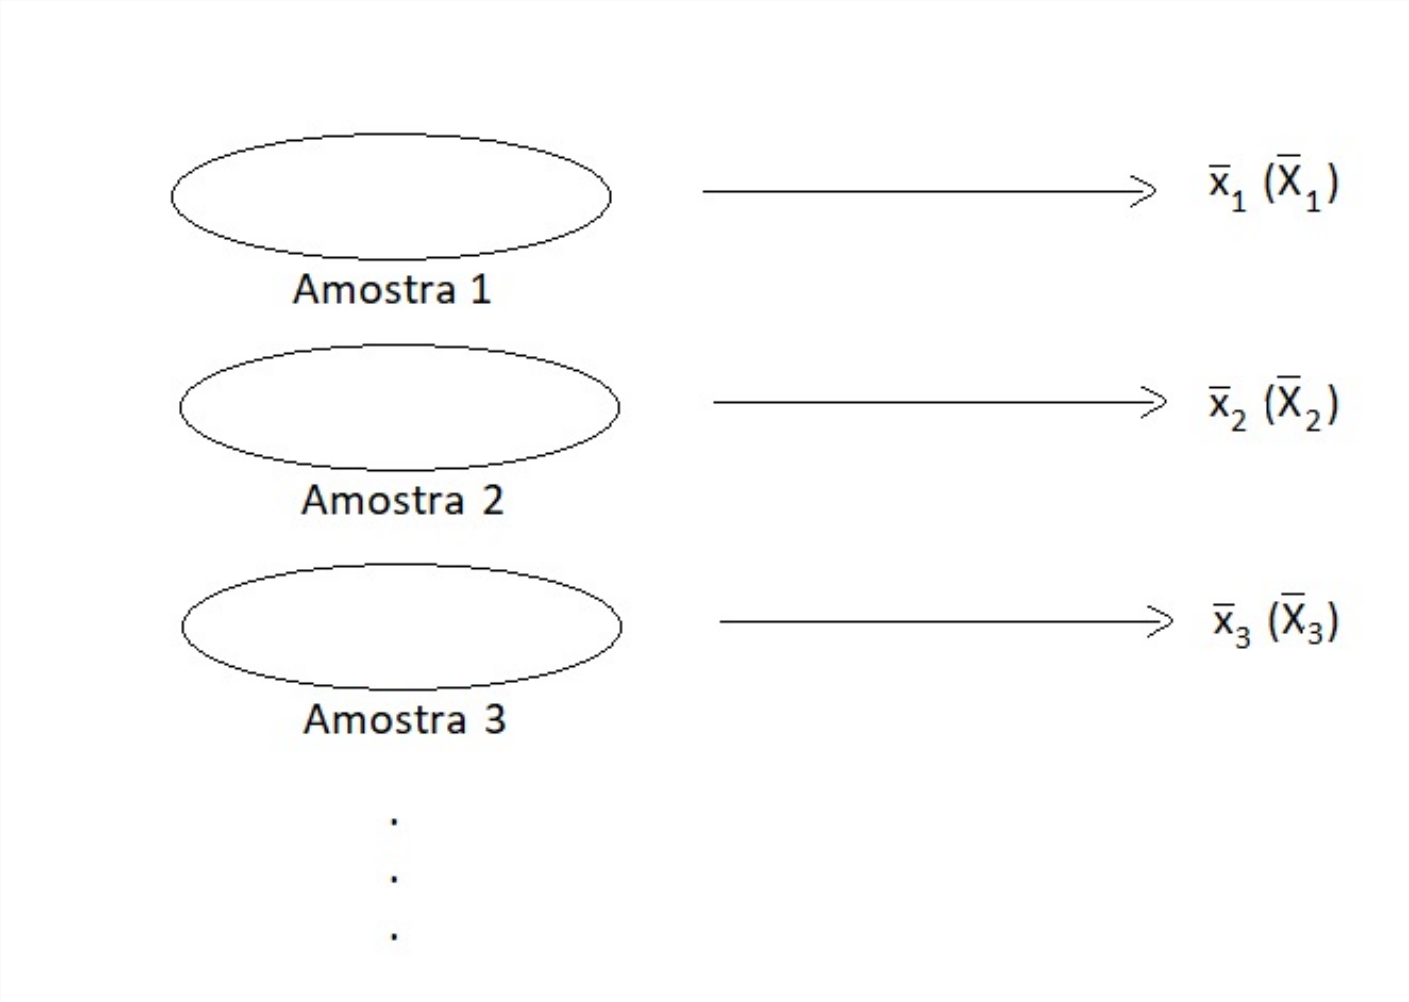
- Tais distribuições serão utilizadas para fazer inferências sobre a população.

Distribuição Amostral da Média

- Estatística: $T(\boldsymbol{X}) = T(X_1, X_2, \ldots, X_n) = \overline{X}$, média amostral.

- Considere uma variável aleatória X, cujos parâmetros média e variância populacional são, respectivamente, $\mu = E(X)$ e $\sigma^2 = Var(X)$.

- Vamos retirar todas as possíveis amostras de tamanho n dessa população e, para cada uma, calcular a média $\overline{X}$.



- Consideremos a distribuição amostral de $\overline{X}$ e estudaremos as suas propriedades.

Teorema

Seja X uma variável aleatória com média μ e variância σ^2 e seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma amostra aleatória de X. Então:

$$E(\overline{X}) = \mu \qquad \text{e} \qquad Var(\overline{X}) = \frac{\sigma^2}{n}$$

Prova:

$$E(\overline{X}) = E\left(\frac{\sum_{i=1}^{n} X_i}{n}\right) = \frac{1}{n}\sum_{i=1}^{n} E(X_i) = \frac{1}{n}\sum_{i=1}^{n} \mu = \frac{1}{n} n\mu = \mu.$$

$$Var(\overline{X}) = Var\left(\frac{\sum_{i=1}^{n} X_i}{n}\right) = \frac{1}{n^2}\sum_{i=1}^{n} Var(X_i) = \frac{1}{n^2}\sum_{i=1}^{n} \sigma^2 = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}.$$

O que acontece com a distribuição de $\overline{X}$ quando aumentamos o tamanho da amostra (n)?

$$E(\overline{X}) = E(X) = \mu$$

e

$$Var(\overline{X}) = \frac{\sigma^2}{n} \to 0$$

Teorema (Teorema do Limite Central - TLC)

Para amostras aleatórias, retiradas de uma população com média μ e variância σ^2 finita, a distribuição amostral da média aproxima-se, para n grande, de uma distribuição normal com média μ e variância σ^2/n:

$$\overline{X} \sim Normal\left(\mu; \frac{\sigma^2}{n}\right).$$

Observação: Observe que se a população for normal, então $\overline{X}$ terá distribuição exata normal.

- Com a distribuição assintótica de $\overline{X}$, temos a seguinte padronização:

$$Z = \frac{\overline{X} - E(\overline{X})}{\sqrt{Var(\overline{X})}} = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim Normal(0; 1).$$

Exemplo 6.1: Uma variável aleatória X tem distribuição normal com média 10 e desvio-padrão 3.

a) Se $\overline{X}$ for a média de uma amostra de 25 elementos retirados dessa população, calcule $P(9 < \overline{X} < 11)$.

b) Que tamanho deveria ter a amostra para que $P(9 < \overline{X} < 11)$=0,95?

Exemplo 6.1: Solução em Python.

```
import math
from scipy.stats import norm
# Parâmetros
Mu_X = 10
Sd_X = 3
# a)
n = 25
Mu_Xbar = Mu_X
Sd_Xbar = Sd_X / math.sqrt(n)
# Cálculo
resultado = norm.cdf(11, loc=Mu_Xbar, scale=Sd_Xbar) - norm.cdf
    (9, loc=Mu_Xbar, scale=Sd_Xbar)
print(resultado)
```

Distribuição Amostral da Proporção

- Seja X uma variável aleatória definida da seguinte maneira:

$$X = \begin{cases} 1, & \text{se ocorre sucesso (interesse)} \\ 0, & \text{se ocorre fracasso} \end{cases}.$$

- Logo, X tem distribuição Bernoulli com média $\mu = E(X) = p$ e variância $\sigma^2 = Var(X) = p(1-p)$.
- Considere também uma amostra aleatória $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ da variável aleatória X.
- Observe que cada X_i, $i = 1, 2, \ldots, n$, tem distribuição Bernoulli com $\mu = E(X_i) = p$ e $\sigma^2 = Var(X_i) = p(1-p)$ e são independentes.

- **Interesse:** a proporção $\hat{p}$ de indivíduos/elementos que possui a característica (sucesso) na amostra. Ou seja:

$$\hat{p} = \frac{\sum_{i=1}^{n} X_i}{n} = \frac{X_1 + X_2 + \ldots + X_n}{n} = \overline{X}.$$

- Pelo TCL, $\hat{p}$ (ou $\overline{X}$) terá distribuição aproximadamente normal com média e variância dadas, respectivamente, por:

$$\mu = E(\hat{p}) = p \qquad \text{e} \qquad \sigma^2 = Var(\hat{p}) = \frac{p(1-p)}{n}.$$

- Ou seja:

$$\hat{p} \sim Normal\left(p; \frac{p(1-p)}{n}\right).$$

- Com a distribuição assintótica de $\hat{p} = \overline{X}$, temos a seguinte padronização:

$$Z = \frac{\hat{p} - E(\hat{p})}{\sqrt{Var(\hat{p})}} = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim Normal(0; 1).$$

Exemplo 6.2: Um procedimento de controle de qualidade foi planejado para garantir um máximo de 10% de itens defeituosos na produção. Suponha que a produção esteja sob controle ($p = 10\%$) e que os itens sejam vendidos em caixas com 100 unidades. Qual a probabilidade de que uma caixa:

a) Tenham mais do que 10% de itens defeituosos?

b) Não tenha itens defeituosos?

Exemplo 6.2: Solução em Python.

```
import math
from scipy.stats import norm

# Parâmetros
p = 0.10
n = 100

# Média e desvio padrão
Mu_pch = p
Sd_pch = math.sqrt(p * (1 - p) / n)

# a)
resultado = 1 - norm.cdf(0.10, loc=Mu_pch, scale=Sd_pch)

print(resultado)
```

Estimação Pontual

- Um dos problemas em inferência estatística é como obter um estimador de determinado parâmetro populacional.
- Alguns métodos para obtenção de estimadores:
  - Método de Mínimos Quadrados.
  - Método dos Momentos.
  - **Método de Máxima Verossimilhança.**
- A seguir discutiremos apenas o método de Máxima Verossimilhança.

Método de Máxima Verossimilhança

- Seja X uma variável aleatória com função massa de probabilidade $p_X(x;\theta)$ ou função densidade de probabilidade $f_X(x;\theta)$, em que θ é o parâmetro, tal que $\theta \in \Theta \subset \mathbb{R}$.

- Considere:

  - $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma amostra aleatória da variável aleatória X;

  - $\boldsymbol{x} = (x_1, x_2, \ldots, x_n)$ uma amostra observada ou vetor de observações de $\boldsymbol{X}$.

Obsevações:

1. θ pode ser um vetor, $\theta = (\theta_1, \ldots, \theta_k)$, com $\theta \in \Theta \subset \mathbb{R}^k$.
2. Iremos considerar apenas os casos em que o suporte da variável aleatória não depende de θ.
3. A função massa de probabilidade conjunta ou função densidade de probabilidade conjunta é dada por:
   - Caso discreto:
   $$p_{\boldsymbol{x}}(x_1, x_2, \ldots, x_n) = \prod_{i=1}^{n} p_{X_i}(x_i; \theta) = \prod_{i=1}^{n} p_X(x_i; \theta);$$
   - Caso contínuo:
   $$f_{\boldsymbol{x}}(x_1, x_2, \ldots, x_n) = \prod_{i=1}^{n} f_{X_i}(x_i; \theta) = \prod_{i=1}^{n} f_X(x_i; \theta).$$

Definição:

Seja $X_1, X_2, \ldots, X_n$ uma amostra aleatória da variável aleatória X. A função de verossimilhança $\mathcal{L}(\theta; \boldsymbol{x})$ é definida por:

$$\mathcal{L}(\theta; \boldsymbol{x}) = \prod_{i=1}^{n} p_X(x_i; \theta)$$

no caso discreto, ou

$$\mathcal{L}(\theta; \boldsymbol{x}) = \prod_{i=1}^{n} f_X(x_i; \theta),$$

no caso contínuo, sendo que $\mathcal{L}(\theta; \boldsymbol{x})$ deve ser vista como uma função de θ.

- Podemos interpretar $\mathcal{L}(\theta; \boldsymbol{x})$ como uma medida de plausibilidade de θ ter produzido o vetor de observações $\boldsymbol{x}$, com a suposta função massa de probabilidade $p_X(x; \theta)$ ou função densidade de probabilidade $f_X(x; \theta)$.

- Vale ressaltar: função de verossimilhança $\neq$ função massa de probabilidade conjunta ou função densidade de probabilidade conjunta.

Definição:

O estimador de máxima verossimilhança (EMV) de θ, denotado por $\hat{\theta}$, é o valor que maximiza a função de verossimilhança $\mathcal{L}(\theta; \boldsymbol{x})$.

Em alguns casos podemos obter o máximo de $\mathcal{L}(\theta; \boldsymbol{x})$ fazendo

$$\frac{\partial \mathcal{L}(\theta; \boldsymbol{x})}{\partial \theta} = 0$$

e verificando se

$$\left.\frac{\partial^2 \mathcal{L}(\theta; \boldsymbol{x})}{\partial \theta^2}\right|_{\theta=\hat{\theta}(\boldsymbol{x})} < 0.$$

Exercício Proposto 6.2: Uma determinada fábrica de computadores monta lotes com 5 computadores para venda. Deseja-se avaliar o número de computadores com defeitos em cada lote. Uma amostra de 10 lotes foi coletada e o número de computadores com defeitos em cada lote foi observado:

$$\boldsymbol{x} = (0, 1, 1, 2, 0, 2, 2, 1, 1, 0).$$

Responda os itens a seguir utilizando um recurso computacional quando possível.

a) Qual a distribuição que poderia explicar o comportamento destes dados?

b) Construa a função de verossimilhança.

c) Avalie esta função considerando diferentes valores do(s) parâmetro(s), fornecendo uma estimativa para este(s).

Definição:

A função log-verossimilhança $\ell(\theta; \boldsymbol{x})$ é definida pelo logaritmo natural de $\mathcal{L}(\theta; \boldsymbol{x})$:

$$\ell(\theta; \boldsymbol{x}) = \log_e \left(\mathcal{L}(\theta; \boldsymbol{x})\right) = \log \left(\mathcal{L}(\theta; \boldsymbol{x})\right)$$

Maximizar $\mathcal{L}(\theta; \boldsymbol{x})$ é equivalente a maximizar $\ell(\theta; \boldsymbol{x})$, o que quase sempre é mais simples. Assim, se $\hat{\theta}$ existe, ele também deve satisfazer a equação de verossimilhança:

$$\frac{\partial \ell(\theta; \boldsymbol{x})}{\partial \theta} = 0.$$

Observação: "log" é a notação usual em Estatística para "ln".

Exemplo 6.3: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma amostra aleatória da variável aleatória X que tem distribuição exponencial com parâmetro α, $\alpha > 0$. Encontrar o EMV para α.

Exemplo 6.4: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma amostra aleatória da variável aleatória X que tem distribuição Normal com parâmetros μ e σ^2, desconhecidos. Encontrar os EMV's dos parâmetros.

Exemplo 6.5: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma amostra aleatória da variável aleatória X que tem distribuição Poisson com parâmetro λ, $\lambda > 0$. Encontrar o EMV para λ.

Exercício Proposto 6.3: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma amostra aleatória da variável aleatória X que tem uma determinada distribuição com parâmetro θ. Encontre o EMV para θ para as distribuições abaixo:

a) X tem distribuição Bernoulli com parâmetro θ, $0 < \theta < 1$.

b) X tem distribuição Binomial com parâmetros M (conhecido) e θ, $0 < \theta < 1$.

c) X tem distribuição Normal com parâmetro de média θ e variância 1, $-\infty < \theta < +\infty$.

Resp.: a) $\hat{\theta} = \overline{X}$; b) $\hat{\theta} = \frac{\overline{X}}{M}$; c) $\hat{\theta} = \overline{X}$.

Propriedade do EMV: Invariância

Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma amostra aleatória da variável aleatória X com função massa de probabilidade $p_x(x;\theta)$ ou função densidade de probabilidade $f_x(x;\theta)$.

Se $\hat{\theta}$ é o EMV de θ, então $g(\hat{\theta})$ é o EMV de $g(\theta)$.

Exemplo 6.7: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma amostra aleatória de tamanho n da variável aleatória X que tem distribuição Poisson com parâmetro θ, $\theta > 0$. Encontrar o EMV para $P(X = 0)$.

Exercício Proposto 6.4: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma amostra aleatória da variável aleatória X que tem distribuição distribuição Bernoulli com parâmetro p, $0 < p < 1$. Encontrar o EMV para $g(p) = p(1-p)$.

Resp.: $g(\hat{p}) = \overline{X}(1 - \overline{X})$.

Propriedades dos Estimadores

- Consideremos uma amostra aleatória $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ da variável aleatória X que descreve uma característica de uma população.

- Seja θ o parâmetro de interesse que desejamos estimar e $T(\boldsymbol{X}) = T(X_1, X_2, \ldots, X_n)$ um estimador para este parâmetro.

a) **Vício (Viés)**

Definição:

O **viés** (vício) de um estimador $T(\boldsymbol{X})$ é a diferença entre $E\big(T(\boldsymbol{X})\big)$ e θ:

$$\mathcal{B}_\theta\big(T(\boldsymbol{X})\big) = E\big(T(\boldsymbol{X})\big) - \theta.$$

Um estimador $T(\boldsymbol{X})$ é definido ser um estimador não-viciado (ou não-viesado) de θ se

$$\mathcal{B}_\theta\big(T(\boldsymbol{X})\big) = 0,$$

ou seja, para todo θ

$$E\big(T(\boldsymbol{X})\big) = \theta.$$

Definição:

Um estimador viciado $T(\boldsymbol{X})$ de θ é dito assintoticamente não-viciado se

$$\lim_{n \to \infty} \mathcal{B}_\theta\big(T(\boldsymbol{X})\big) = 0.$$

b) **Erro Quadrático Médio**

Definição:

O **Erro Quadrático Médio (EQM)** de um estimador $T(\boldsymbol{X})$ de θ é definido por:

$$EQM_\theta\big(T(\boldsymbol{X})\big) = E\big((T(\boldsymbol{X}) - \theta)^2\big),$$

que é uma medida de desempenho razoável para um estimador.

- O EQM pode ser determinado pela média e variância de $T(\boldsymbol{X})$:

$$\begin{aligned} EQM_\theta\big(T(\boldsymbol{X})\big) &= Var\big(T(\boldsymbol{X})\big) + \big\{E\big(T(\boldsymbol{X})\big) - \theta\big\}^2 \\ &= Var\big(T(\boldsymbol{X})\big) + \big\{\mathcal{B}_\theta\big(T(\boldsymbol{X})\big)\big\}^2. \end{aligned}$$

Prova:

$$\begin{aligned} EQM_\theta\big(T(\boldsymbol{X})\big) &= E\big((T(\boldsymbol{X}) - \theta)^2\big) \\ &= E\big(T^2(\boldsymbol{X}) - 2\theta T(\boldsymbol{X}) + \theta^2\big) \\ &= E\big(T^2(\boldsymbol{X})\big) - 2\theta E\big(T(\boldsymbol{X})\big) + \theta^2 \\ &= E\big(T^2(\boldsymbol{X})\big) - \big\{E\big(T(\boldsymbol{X})\big)\big\}^2 + \big\{E\big(T(\boldsymbol{X})\big)\big\}^2 - 2\theta E\big(T(\boldsymbol{X})\big) + \theta^2 \\ &= Var\big(T(\boldsymbol{X})\big) + \big\{E\big(T(\boldsymbol{X})\big) - \theta\big\}^2 \\ &= Var\big(T(\boldsymbol{X})\big) + \big\{\mathcal{B}_\theta\big(T(\boldsymbol{X})\big)\big\}^2. \end{aligned}$$

c) Eficiência

Definição:

Considere dois estimadores $T_1(\boldsymbol{X}) = \hat{\theta}_1$ e $T_2(\boldsymbol{X}) = \hat{\theta}_2$ não-viciados para um parâmetro θ.

Dizemos que $T_1(\boldsymbol{X}) = \hat{\theta}_1$ é mais eficiente que $T_2(\boldsymbol{X}) = \hat{\theta}_2$ se

$$Var\big(T_1(\boldsymbol{X})\big) < Var\big(T_2(\boldsymbol{X})\big).$$

d) **Consistência**

Definição:

Seja $\{T_n(\boldsymbol{X})\}_{n\geq 1}$ uma sequência de estimadores de θ:

$$\{T_1(X_1); T_2(X_1, X_2); T_3(X_1, X_2, X_3); \ldots; T_k(X_1, X_2, \ldots, X_k); \ldots\}.$$

A sequência $\{T_n\}_{n\geq 1}$ é definida ser uma sequência consistente de estimadores de θ se, para todo $\varepsilon > 0$, satisfaz:

$$\lim_{n\to\infty} P\big(|T_n(\boldsymbol{X}) - \theta| \geq \varepsilon\big) = 0.$$

- Em geral, para verificar se um estimador é consistente, utilizamos a **Desigualdade de Chebyshev** que diz:

$$P\big(|T_n(\boldsymbol{X}) - \theta| \geq \varepsilon\big) \leq \frac{Var\big(T(\boldsymbol{X})\big)}{\varepsilon^2}.$$

Proposição:

Uma sequência $\left\{T_n(\boldsymbol{X})\right\}_{n\geq 1}$ de estimadores de θ é consistente se:

$$\lim_{n\to\infty} E\left(T_n(\boldsymbol{X})\right) = \theta$$

e

$$\lim_{n\to\infty} Var\left(T_n(\boldsymbol{X})\right) = 0.$$

Exemplo 6.8: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma amostra aleatória da variável aleatória X com distribuição $N(\mu; \sigma^2)$. Considere os estimadores de μ e σ^2, respectivamente:

$$\hat{\mu} = \overline{X} \qquad \text{e} \qquad \hat{\sigma}^2 = \frac{\sum_{i=1}^{n}(X_i - \overline{X})^2}{n}.$$

Calcule os vícios para estes estimadores.

Observação: O cálculo do viés de um estimador pode ser usado para sugerir novos estimadores.

Exemplo 6.9: Considere o estimador $\hat{\sigma}^2$ de σ^2, cujo o vício é $-\sigma^2/n$. Obtenha um novo estimador não-viciado.

Exemplo 6.10: Considere uma amostra de tamanho n da variável aleatória X com distribuição $N(\mu; \sigma^2)$. Considere dois estimadores para μ:

$$\hat{\mu}_1 = X_1 \qquad \text{e} \qquad \hat{\mu}_2 = \overline{X}.$$

a) Qual dos estimadores é melhor do ponto de vista da eficiência?

b) E do ponto de vista da consistência?

Exemplo 6.11: Considere os estimadores $\hat{\sigma}^2$ e S^2 para σ^2. Compare os seus EQM e verifique se estes estimadores são consistentes. Utilize o seguinte resultado:

$$Y = \frac{\sum_{i=1}^{n}(X_i - \overline{X})^2}{\sigma^2} \sim \chi^2_{(n-1)},$$

sendo $E(Y) = n - 1$ e $Var(Y) = 2(n-1)$.